

Cómputo Estadístico

Tarea 6

Marcelo Alberto Sanchez Zaragoza

24 de noviembre de 2021

1. PROBLEMA 1

Es bien sabido que la regresión ridge tiende a dar valores de coeficientes similares a las variables correlacionadas, mientras que lasso puede dar valores de coeficientes totalmente diferentes a las variables correlacionadas. Se explorará esta propiedad en un entorno sencillo.

Supongamos que $n = 20, p = 2, x_{11} = x_{12}, x_{21} = x_{22}$. Además, supongamos que $y_1 + y_2 = 0$ y $x_{11} + x_{21} = 0$ y $x_{12} + x_{22} = 0$, de modo que la estimación del intercepto en minutos cuadros, regresión de Ridge o en el modelo de lasso es cero: $\hat{\gamma} = 0$.

- a) Plantea el problema de la optimización con la regresión ridge bajo estas suposiciones.

- b) Argumenta que bajo estas suposiciones, las estimaciones de los coeficientes de ridge satisfacen $\hat{\beta}_1 = \hat{\beta}_2$.
- c) Planten el problema de la optimización con la regresión lasso bajo estas suposiciones.
- d) Argumenta que en este contexto, los coeficientes de lasso $\hat{\beta}_1$ y $\hat{\beta}_2$ no son únicos; es decir, hay muchas soluciones posibles al problema de optimización en (c). Describe estas soluciones.

Solución

Inciso a)

Tenemos que una forma general de optimización de regresión ridge es igual a:

$$Min : \sum_{i=1}^n (y_i - \hat{\beta}_0 - \sum_{j=1}^p \hat{\beta}_j x_{ij})^2 + \lambda \sum_{i=1}^p \hat{\beta}_i^2$$

dado que el problema menciona que $\beta_0 = 0$ y que $n = p = 2$ tenemos lo siguiente:

$$Min : (y_1 + \hat{\beta}_1 x_{11} - \hat{\beta}_2 x_{12})^2 + (y_2 - \hat{\beta}_1 x_{21} - \hat{\beta}_2 x_{22})^2 + \lambda(\hat{\beta}_1^2 + \hat{\beta}_2^2)$$

$$f(\hat{\beta}_1, \hat{\beta}_2) = (y_1 + \hat{\beta}_1 x_{11} - \hat{\beta}_2 x_{12})^2 + (y_2 - \hat{\beta}_1 x_{21} - \hat{\beta}_2 x_{22})^2 + \lambda(\hat{\beta}_1^2 + \hat{\beta}_2^2)$$

Inciso b)

Ahora vamos a derivar la expresión anterior respecto a $\hat{\beta}_1$ y $\hat{\beta}_2$, posteriormente igualar a cero y encontrar expresiones para los beta.

Derivando la expresión vamos tenemos:

$$\frac{\partial f}{\partial \hat{\beta}_1} = 2(y_1 - \hat{\beta}_1 x_{11} - \hat{\beta}_2 x_{12})(-x_{11}) + 2(y_2 - \hat{\beta}_1 x_{21} - \hat{\beta}_2 x_{22})(-x_{21}) + 2\lambda\hat{\beta}_1 = 0$$

dado que $x_{12} = x_{11}$ y $x_{22} = x_{21}$, tenemos:

$$\begin{aligned}\hat{\beta}_1(x_{11}^2 + x_{21}^2 + \lambda) - y_1x_{11} - y_2x_{21} + \hat{\beta}_2(x_{11}^2 + x_{21}^2) &= 0 \\ \hat{\beta}_1 &= \frac{y_1x_{11} + y_2x_{21} - \hat{\beta}_2(x_{11}^2 + x_{21}^2)}{(x_{11}^2 + x_{21}^2 + \lambda)}\end{aligned}$$

Analogamente realizamos el mismo procedimiento para $\hat{\beta}_2$ y obtuvimos:

$$\hat{\beta}_2 = \frac{y_1x_{11} + y_2x_{21} - \hat{\beta}_1(x_{11}^2 + x_{21}^2)}{(x_{11}^2 + x_{21}^2 + \lambda)}$$

Observando estos resultados podemos decir que $\hat{\beta}_1 = \hat{\beta}_2$.

Inciso c)

Ahora proponemos un problema de optimización para la regresión lasso, tenemos:

$$Min : (y_1 + \hat{\beta}_1x_{11} - \hat{\beta}_2x_{12})^2 + (y_2 - \hat{\beta}_1x_{21} - \hat{\beta}_2x_{22})^2 + \lambda(|\hat{\beta}_1| + |\hat{\beta}_2|)$$

$$g(\hat{\beta}_1, \hat{\beta}_2) = (y_1 + \hat{\beta}_1x_{11} - \hat{\beta}_2x_{12})^2 + (y_2 - \hat{\beta}_1x_{21} - \hat{\beta}_2x_{22})^2 + \lambda(|\hat{\beta}_1| + |\hat{\beta}_2|)$$

Inciso d)

2. PROBLEMA 2

Considerando el conjunto de datos *College* de la librería ISLR, vamos a predecir el número de solicitudes recibidas (APPs) usando las otras variables del conjunto de datos.

- a) Divide el conjunto de datos en un conjunto de entrenamiento y un conjunto de prueba y ajusta un modelo lineal usando mínimos cuadrados en el conjunto de entrenamiento. Reporta el error de prueba obtenido.

- b) Ajusta un modelo de regresión Ridge sobre el conjunto de entrenamiento, con α elegido por validación cruzada. Reporta el error de prueba obtenido.
- c) Ajusta un modelo de lasso en el conjunto de entrenamiento, con α elegido por validación cruzada. Reporta el error de prueba obtenido, junto con el número de estimaciones de coeficientes no nulos.
- d) Ajusta un modelo PCR en el conjunto de entrenamiento, con M elegido por la validación cruzada. Reporta el error de prueba obtenido, junto con el valor de M seleccionado mediante validación cruzada.
- e) Ajusta un modelo PLS en el conjunto de entrenamiento, con M elegido por la validación cruzada. Informe el error de prueba obtenido, junto con el valor de M seleccionado mediante validación cruzada.
- f) Comenta los resultados obtenidos. ¿ Con qué precisión podemos predecir el número de solicitudes de estudios universitarios recibidas?
¿ Hay mucha diferencia entre los errores de prueba resultantes de estos cinco enfoques?

Solución

Inciso a)

Realizamos la división de los datos en la siguientes lineas de código.

```
library(ISLR)
set.seed(1)
sum(is.na(College))

[1] 0

length(College[,1])

[1] 777
```

```

train.size = dim(College)[1] / 2 #621
train = sample(1:dim(College)[1], train.size)
length(train)

[1] 388

test = -train
College.train = College[train, ]
College.test = College[test, ]
length(College.test[,1])

[1] 389

length(College.train[,1])

[1] 388

```

Inciso b)

En este caso ajustamos un modelo de regresión Ridge sobre el conjunto de entrenamiento, donde primero encontramos el valor de α .

```

library(glmnet)
train.mat = model.matrix(Apps~., data=College.train)
test.mat = model.matrix(Apps~., data=College.test)
grid = 10^seq(10, -2, length=100)
mod.ridge = cv.glmnet(train.mat,
                      College.train[, "Apps"],
                      alpha=0, lambda=grid,
                      thresh=1e-12)
lambda.best = mod.ridge$lambda.min
lambda.best

[1] 0.01

```

```
ridge.pred = predict(mod.ridge, newx=test.mat, s=lambda.best)
mean((College.test[, "Apps"] - ridge.pred)^2)

[1] 1135714
```

El valor de $\alpha = 0,01$ y un error de 1135714.

Inciso c)

En este caso ajustamos un modelo de regresión lasso sobre el conjunto de entrenamiento, donde primero encontramos el valor de α .

```
library(glmnet)
mod.lasso = cv.glmnet(train.mat, College.train[, "Apps"],
                      alpha=1, lambda=grid,
                      thresh=1e-12)
lambda.best = mod.lasso$lambda.min
lambda.best

[1] 0.01

lasso.pred = predict(mod.lasso, newx=test.mat, s=lambda.best)
mean((College.test[, "Apps"] - lasso.pred)^2)

[1] 1135659

mod.lasso = glmnet(model.matrix(Apps~., data=College),
                  College[, "Apps"],
                  alpha=1)
predict(mod.lasso, s=lambda.best, type="coefficients")

19 x 1 sparse Matrix of class "dgCMatrix"
      s1
(Intercept) -471.39372069
```

```

(Intercept)      .
PrivateYes    -491.04485135
Accept         1.57033288
Enroll        -0.75961467
Top10perc      48.14698891
Top25perc     -12.84690694
F.Undergrad    0.04149116
P.Undergrad    0.04438973
Outstate      -0.08328388
Room.Board     0.14943472
Books          0.01532293
Personal       0.02909954
PhD            -8.39597537
Terminal       -3.26800340
S.F.Ratio      14.59298267
perc.alumni    -0.04404771
Expend         0.07712632
Grad.Rate      8.28950241

```

El valor de $\alpha = 0,01$ y un error de 1135659 y mostramos aquellos coeficientes que son distintos de cero.

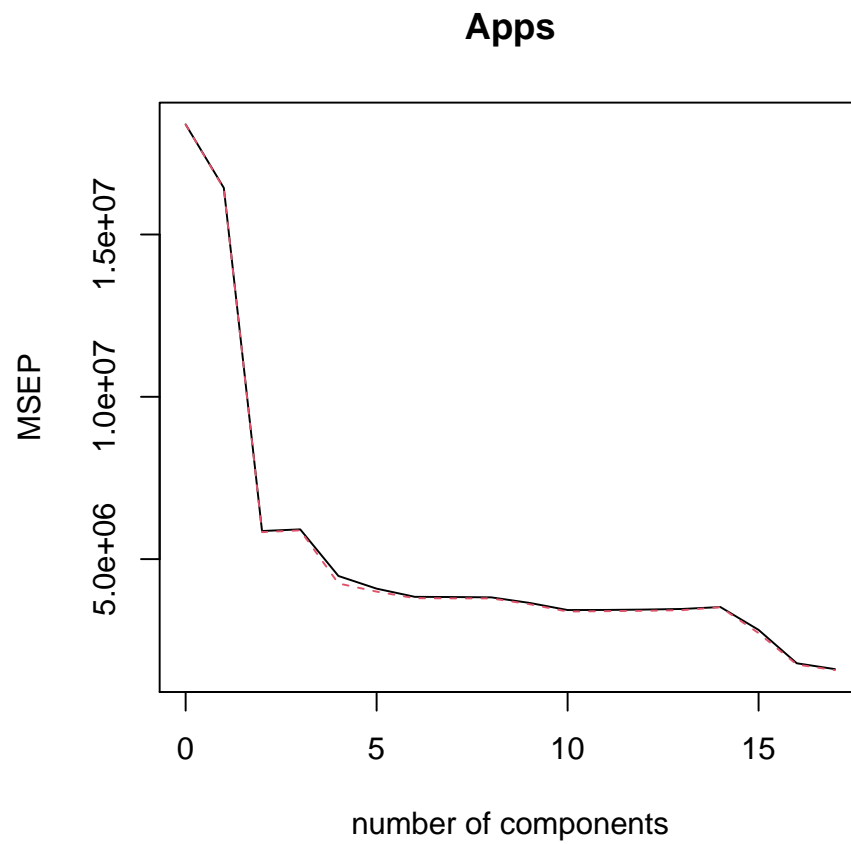
Inciso d)

Ajustamos un modelo PCR en el conjunto de entrenamiento y se muestra el gráfico.

```

library(pls)
pcr.fit = pcr(Apps~., data=College.train, scale=T, validation="CV")
validationplot(pcr.fit, val.type="MSEP")

```



```
pcr.pred = predict(pcr.fit, College.test, ncomp=10)
length(pcr.pred)

[1] 389

length(College.test[, 'Apps'])

[1] 389
```



```
mean((College.test[, "Apps"] - pcr.pred[1:389] )^2)

[1] 1723100
```


El error obtenido fue 1723100, con 10 componentes.

Inciso e)

Ajustamos un modelo PLS en el conjunto de entrenamiento y se muestra el gráfico.

```
pls.fit = plsr(Apps~., data=College.train, scale=T, validation="CV")
validationplot(pls.fit, val.type="MSEP")
```

Apps



```
pls.pred = predict(pls.fit, College.test, ncomp=10)
mean((College.test[, "Apps"] - pls.pred[1:389] )^2) #156
[1] 1131661
```

El error obtenido fue 1131661, con 10 componentes.

Inciso f)


```
test.avg = mean(College.test[, "Apps"])
#lm.test.r2 = 1 - mean((College.test[, "Apps"] - lm.pred)^2) / mean((College.test[, "
ridge.test.r2 = 1 - mean((College.test[, "Apps"] -
                      ridge.pred)^2) / mean((College.test[, "Apps"]
                      - test.avg)^2)

lasso.test.r2 = 1 - mean((College.test[, "Apps"] -
                      lasso.pred)^2) / mean((College.test[, "Apps"]
                      - test.avg)^2)

pcr.test.r2 = 1 - mean((College.test[, "Apps"] -
                      pcr.pred[1:389] )^2) / mean((College.test[, "Apps"]
                      - test.avg)^2)

pls.test.r2 = 1 - mean((College.test[, "Apps"] -
                      pls.pred[1:389] )^2) / mean((College.test[, "Apps"]
                      - test.avg)^2)

barplot(c(ridge.test.r2, lasso.test.r2, pcr.test.r2, pls.test.r2),
        col="green", names.arg=c("Ridge", "Lasso", "PCR", "PLS"),
        main="Test R-squared")
```



En el gráfico observamos que el mejor resultados dio para poder predecir el número de solicitudes de estudios universitarios es PCR ya que su R^2 fue menor que todos los demás, igual podemos observar que los valores para Ridge, Lasso y PLS se observan muy parecidas entre ellas.